

KESIMPULAN PERBANDINGAN METODE KLASTERING

K-Means dan DBSCAN pada Dataset Diabetes Health Indicators (BRFSS 2015)

Maulidya Afriani | NIM 244107020059 | TI-3G | Kuis 1 Pembelajaran Mesin, Kelompok 4

1. Kesimpulan Utama

Dari enam kombinasi metode yang diuji, **K-Means dengan jarak Euclidean** paling sesuai untuk dataset ini: terbaik di antara ketiga varian K-Means pada semua ukuran mutu, memakai seluruh data tanpa membuang noise, dan menghasilkan kluster yang seimbang serta mudah ditafsirkan. DBSCAN tampak unggul pada skor Silhouette, tetapi skor itu dihitung tanpa titik noise dan hampir semua data tergabung dalam satu kluster besar, sehingga tidak memberi segmentasi yang berguna.

2. Data dan Preprocessing

Semua metode dibandingkan pada data yang sama. Dari 10.000 baris awal, kelas 1 (pra-diabetes, 180 baris) dibuang agar fokus pada diabetes dan non-diabetes. Kolom Income dan Cluster (sisa hasil kluster lama) dibuang, lalu 243 baris duplikat dihapus sehingga tersisa 9.577 baris. Kolom Diabetes_012 dipisahkan sebagai label (tidak dipakai membentuk kluster, hanya untuk membaca profil kluster), dan 20 fitur distandardisasi dengan StandardScaler. Hasil akhir: matriks 9.577×20 .

3. Hasil Perbandingan

K-Means memakai $k = 4$ (metode siku pada Euclidean) dan dinilai dengan ukuran yang sama, yaitu Silhouette Euclidean pada data standar. DBSCAN memakai $\text{min_samples} = 21$, dengan eps terbaik yang menghasilkan minimal dua kluster, dan dinilai tanpa titik noise.

Metode	Kluster	Noise	Silhouette	DBI ↓	CHI ↑	Diabetes per kluster
K-Means Euclidean	4	0%	0,090	2,53	823	3–33%
K-Means Manhattan	4	0%	0,038	3,50	531	6–37%
K-Means Cosine	4	0%	0,051	2,99	699	3–29%
DBSCAN Euclidean (eps 3)	7	20,6%	0,200	1,44	369	1–27%
DBSCAN Manhattan (eps 5)	2	22,8%	0,299	1,16	431	1–11%
DBSCAN Cosine (eps 0,25)	2	3,0%	0,163	1,75	427	5–15%

Baris hijau adalah metode terpilih.

4. Alasan K-Means Euclidean Dipilih

- Terbaik di antara K-Means:** Silhouette tertinggi (0,090 vs 0,038 dan 0,051), DBI terendah, CHI tertinggi. Data sudah berskala z-score sehingga jarak Euclidean sesuai.
- Seluruh data terpakai:** semua 9.577 responden mendapat kluster, sedangkan DBSCAN membuang 20–23% data sebagai noise.
- Kluster seimbang dan bermakna:** ukuran 4.170, 3.381, 1.480, dan 546; proporsi diabetes antar kluster berbeda jelas (3% sampai 33%), sehingga ada kelompok berisiko rendah dan tinggi.
- Stabil dan cepat:** tidak bergantung pada parameter sensitif, waktu komputasi sekitar 0,06 detik.

5. Hasil Metode Lain dan Alasan Tidak Dipilih

- K-Means Manhattan:** terendah di antara K-Means. Konvergen cepat (4 iterasi) tetapi kluster kurang kompak; median sebagai pusat kurang informatif pada fitur biner.

- **K-Means Cosine:** ukuran klaster paling seimbang, tetapi mutunya di bawah Euclidean karena hanya melihat arah vektor dan mengabaikan besar nilai fitur.
- **DBSCAN Euclidean:** paling layak di antara DBSCAN (7 klaster, noise 20,6%), namun satu klaster menguasai sekitar 65% data.
- **DBSCAN Manhattan:** skor tertinggi di atas kertas (0,299) tetapi hanya 2 klaster, satu klaster mencakup sekitar 94% data non-noise. Sangat peka terhadap eps: eps 4 membuang 34% data, eps 6 hanya menghasilkan 1 klaster.
- **DBSCAN Cosine:** paling tidak stabil: menjadi 1 klaster pada eps 0,35 ke atas, tetapi 33 klaster dengan 64% noise pada eps 0,1.

Skor Silhouette DBSCAN yang lebih tinggi menyesatkan karena noise dikeluarkan dari penilaian. Data kesehatan berdimensi 20 dengan banyak fitur biner juga tidak memiliki kelompok padat yang terpisah jelas, sehingga kepadatan sulit dibedakan.

6. Keterbatasan

- Silhouette K-Means Euclidean hanya 0,09: struktur klaster lemah dan saling tumpang tindih, wajar pada data kesehatan populasi.
- Kecocokan klaster dengan label diabetes rendah pada semua metode (NMI di bawah 0,08), jadi klaster bukan pengganti diagnosis.
- Untuk segmentasi seluruh responden, K-Means Euclidean paling cocok; untuk mendeteksi kelompok tidak biasa (outlier), DBSCAN lebih relevan.
- Angka di dokumen ini dari data seragam 9.577×20 ; hasil anggota lain yang memakai data berbeda perlu dihitung ulang sebelum masuk tabel akhir.